



MCDI500

Evaluación Sumativa 1 — Fase 1

Implementación inicial del entorno reproducible y documentación técnica

Informe técnico grupal · 20%

Título del proyecto:

Factores socioeconómicos y de preparación previa asociados al rendimiento académico

Integrantes: *Juan de Dios Díaz Ríos*

Francisco Fariña Molina

Constanza Moreno Giacometto

Yenne Sepúlveda Jerez

Curso: *MCDI500 — Programación para la Ciencia de Datos*

Docente: Omar Salinas Silva

Fecha: 09/06/2026

ÍNDICE

I. Introducción y contextualización	3
II. Definición de la problemática y objetivos del proyecto	4
III. Aplicación de herramientas científicas	6
IV. Reproducibilidad técnica	8
V. Control de versiones	10
VI. Notebook F1_Definicion.ipynb	11
VII. Documentación del proceso	12
VIII. Repositorio GitHub correspondiente a la Fase 1	12
IX. Vinculación del mapa conceptual con el avance del proyecto	13
X. Bibliografía (APA 7)	15

I. Introducción y contextualización

El presente informe corresponde a la Fase 1 ABP del proyecto transversal de la asignatura Programación para la Ciencia de Datos del Magíster en Ciencia de Datos e Inteligencia Artificial impartido por la Universidad Andrés Bello. El proyecto se desarrolla en el ámbito educativo, un área en la que el rendimiento académico constituye una temática de gran interés debido a su impacto en los procesos de aprendizaje y en la toma de decisiones basadas en evidencia. En este contexto, se seleccionó el conjunto de datos Student Performance Dataset, desarrollado por Cortez y Silva (2008) y disponible en el repositorio UCI Machine Learning Repository (Dua y Graff, 2019), por la amplitud y diversidad de información que proporciona sobre variables individuales, familiares, socioeconómicas, hábitos de estudio y antecedentes académicos asociados al desempeño de los estudiantes.

El dataset contiene información de dos establecimientos educacionales portugueses: Gabriel Pereira (GP) y Mousinho da Silveira (MS), e incluye registros de 649 estudiantes de la asignatura de Portugués y 395 estudiantes de Matemáticas, cada uno descrito mediante 33 variables que abarcan factores directos del rendimiento (studytime, failures, absences), contexto familiar (Medu, Fedu, famrel), comportamiento social (goout, Dalc, Walc) y perfil sociodemográfico (sex, age, school, address), entre otras y calificaciones parciales y finales. La variable objetivo central es G3 (calificación final, escala 0–20), cuya predicción y comprensión constituye el propósito analítico del proyecto.

La problemática abordada en este proyecto consiste en comprender qué factores socioeconómicos y de preparación previa podrían explicar las diferencias en el rendimiento académico entre estudiantes de dos establecimientos educacionales. La riqueza y cantidad de variables disponibles ofrecen una oportunidad para estudiar el fenómeno desde una perspectiva integral e identificar patrones y relaciones entre distintos factores que influyen en los resultados de aprendizaje. En este contexto, el objetivo general del proyecto es:

Identificar y analizar los factores socioeconómicos y de preparación previa que podrían explicar las diferencias en el rendimiento académico entre estudiantes de dos establecimientos educacionales, mediante técnicas de análisis exploratorio y modelado predictivo sobre el Student Performance Dataset.

La complejidad de la problemática y la cantidad de información disponible justifican la utilización de un enfoque basado en programación, análisis de datos, visualización y modelación, ya que estas herramientas permiten identificar patrones, establecer relaciones entre variables y generar evidencia para apoyar la comprensión del fenómeno estudiado. Asimismo, el uso de un flujo de trabajo reproducible contribuye a asegurar la trazabilidad, consistencia y confiabilidad de los resultados obtenidos, conforme a los lineamientos del curso (Salinas, 2026a; Universidad Andrés Bello, 2026b).

El proyecto se desarrolla en cuatro fases progresivas e interdependientes:

Fase 1 (F1): Definición del problema, configuración del entorno reproducible con Python, Jupyter Lab, Git y GitHub, y carga inicial del dataset. Esta fase establece las bases técnicas y metodológicas del proyecto.

Fase 2 (F2): Exploración y limpieza de datos (EDA): estadísticas descriptivas, análisis de correlaciones, detección de valores atípicos, codificación de variables categóricas y normalización.

Fase 3 (F3): Análisis y modelado predictivo mediante regresión lineal múltiple y árboles de decisión, identificando los factores de mayor incidencia en el rendimiento académico.

Fase 4 (F4): Evaluación de resultados, comunicación de hallazgos y documentación final del proyecto.

De acuerdo con lo anterior, el presente informe establece las bases conceptuales, metodológicas y técnicas necesarias para el desarrollo de las fases posteriores del proyecto y la generación de resultados reproducibles.

II. Definición de la problemática y objetivos del proyecto

Formulación de la problemática

El rendimiento académico es un fenómeno complejo influenciado por múltiples factores de carácter individual, familiar, socioeconómico y educativo. En este contexto, la problemática abordada en el presente proyecto consiste en determinar qué factores socioeconómicos y de preparación previa podrían explicar las diferencias en el rendimiento académico entre estudiantes de secundaria de dos establecimientos educacionales portugueses. Para ello, se empleará un enfoque basado en programación y análisis de datos, utilizando información proveniente del conjunto de datos Student Performance Dataset, con el propósito de identificar patrones y relaciones que permitan comprender de mejor manera los factores asociados al desempeño estudiantil.

La riqueza y diversidad de la información disponible constituyen una oportunidad para estudiar el fenómeno desde una perspectiva integral. El conjunto de datos incorpora variables relacionadas con características individuales, familiares, socioeconómicas, hábitos de estudio, apoyo institucional y antecedentes académicos, lo que permite analizar la influencia conjunta de distintos factores sobre los resultados de aprendizaje y generar evidencia para apoyar la comprensión del rendimiento académico.

Preguntas centrales del análisis

Las siguientes preguntas orientan el desarrollo del proyecto y la búsqueda de evidencias, métricas y patrones relevantes:

- ¿Qué factores socioeconómicos y familiares presentan una mayor asociación con el rendimiento académico de los estudiantes?

- ¿De qué manera las características individuales y los hábitos de estudio influyen en las calificaciones obtenidas?
- ¿Existen diferencias significativas en el rendimiento académico entre estudiantes de distintos establecimientos educacionales?
- ¿Qué variables presentan una mayor capacidad explicativa respecto de las diferencias observadas en los resultados académicos?
- ¿Qué variables presentan una mayor capacidad predictiva sobre la calificación final G3?

Objetivo general

Identificar y analizar los factores socioeconómicos y de preparación previa que explican las diferencias en el rendimiento académico entre estudiantes de dos establecimientos educacionales, mediante técnicas de análisis exploratorio y modelado predictivo sobre el Student Performance Dataset (Cortez y Silva, 2008).

Nº	Objetivo específico	Fase
OE1	Configurar un entorno de trabajo reproducible con Python, Jupyter Lab, Git y GitHub, estableciendo la estructura técnica del proyecto conforme a las buenas prácticas del software científico.	F1
OE2	Realizar la carga, inspección y limpieza del Student Performance Dataset, verificando la integridad, calidad y estructura de los datos para garantizar su adecuación al análisis posterior.	F1 – F2
OE3	Ejecutar un análisis exploratorio de datos (EDA) que permita identificar distribuciones, correlaciones y patrones iniciales entre las variables socioeconómicas y el rendimiento académico.	F2
OE4	Desarrollar y evaluar modelos predictivos —regresión lineal múltiple y árboles de decisión— para identificar los factores de mayor incidencia en la calificación final G3.	F3
OE5	Documentar y comunicar los hallazgos del proyecto mediante notebooks reproducibles, un repositorio GitHub estructurado y un informe técnico formal.	F1 – F4

Alcance del proyecto

El alcance del proyecto considera el análisis de la información contenida en el conjunto de datos Student Performance Dataset, limitándose a las variables disponibles en dicho repositorio y a las etapas definidas en el flujo de trabajo del proyecto.

La Fase 1 contempla la definición del problema, la implementación del entorno reproducible y la documentación técnica; la Fase 2 abordará la exploración y preparación de los datos; la Fase 3 comprenderá las actividades de análisis, modelado y evaluación de resultados; y la Fase 4 estará orientada a la consolidación de las conclusiones y la documentación final.

En consecuencia, este proyecto no considera la incorporación de fuentes de datos externas, la generación de nuevos datos ni la aplicación de técnicas avanzadas de aprendizaje profundo, concentrándose en técnicas estadísticas y modelos predictivos tradicionales.

Supuestos relevantes

Para la correcta interpretación de los resultados obtenidos, se consideran los siguientes supuestos:

- El conjunto de datos Student Performance Dataset corresponde a los datos originales sin modificaciones del repositorio UCI (Cortez y Silva, 2008; Dua y Graff, 2019).
- La variable G3, correspondiente a la calificación final del estudiante, será considerada como la variable objetivo principal del proyecto, al constituir un indicador global del rendimiento académico.
- Los resultados obtenidos estarán condicionados por las características propias del conjunto de datos, su naturaleza transversal y su contexto geográfico específico, por lo que las conclusiones deberán interpretarse dentro de dichas limitaciones.

III. Aplicación de herramientas científicas

El desarrollo del proyecto se sustenta en el ecosistema científico de Python, utilizando herramientas que permiten implementar un flujo de trabajo reproducible y facilitar las tareas de preparación, transformación y análisis de datos. La integración de estas herramientas posibilita abordar la problemática planteada de manera sistemática, garantizando la trazabilidad y consistencia del proceso analítico.

La Tabla 1 presenta las principales herramientas y librerías que serán utilizadas durante el desarrollo del proyecto.

Herramienta	Función principal	Etapas donde se utiliza
Python	Lenguaje para carga, procesamiento, limpieza, análisis y modelado de datos.	Carga, EDA, limpieza, análisis, evaluación.
Pandas	Lectura de CSV, manejo de tablas, selección de columnas y transformaciones.	Carga, EDA, limpieza.
NumPy	Apoyo para operaciones numéricas y manejo de datos.	Limpieza y análisis.
Matplotlib	Visualizaciones básicas y gráficos para comunicar resultados.	EDA y evaluación.
Scikit-Learn	Modelado y evaluación de algoritmos en fases posteriores.	Análisis/modelado proyectado.
Statsmodels	Modelos estadísticos, por ejemplo regresión lineal múltiple.	Modelado proyectado.
Jupyter Lab	Entorno para combinar código, Markdown, resultados y documentación reproducible.	Todas las etapas.


Git	Control de versiones local, historial de cambios y trazabilidad.	Todas las etapas.
GitHub	Respaldo remoto, colaboración, revisión y Pull Requests.	Todas las etapas.

Las herramientas seleccionadas se integran de manera complementaria a lo largo del proyecto. En las primeras etapas, Python y Jupyter Lab permitirán desarrollar notebooks reproducibles para documentar las actividades realizadas. Durante la fase de exploración y preparación de datos, Pandas y NumPy serán utilizados para la carga, transformación y análisis inicial de la información. Posteriormente, Matplotlib facilitará la generación de visualizaciones y Scikit-learn permitirá implementar y evaluar modelos predictivos. Por su parte, Git y GitHub proporcionarán mecanismos de control de versiones y colaboración, garantizando la trazabilidad y reproducibilidad del proyecto (Universidad Andrés Bello, 2026a). Las librerías utilizadas cuentan con documentación oficial que respalda su uso: pandas (The pandas development team, 2024), NumPy (NumPy Developers, 2024) y el preprocesamiento de datos sigue los lineamientos de García et al. (2015).


La implementación del proyecto seguirá una secuencia lógica de procesamiento, donde cada componente cumple una función específica dentro del flujo reproducible:



La organización del proyecto se complementa con una estructura de directorios definida previamente controlada con Git y respaldada en GitHub, separando los datos originales, los datos procesados, la documentación técnica y los notebooks de trabajo desarrollados en Python. Esta organización busca mantener un flujo ordenado entre la adquisición de información, su preparación y las etapas posteriores de análisis y modelado contempladas para las siguientes fases del proyecto.



Además, se crean 2 archivos py para administrar las librerías utilizadas y la funciones que se llamarán en los notebooks del proyecto.



IV. Reproducibilidad técnica

Para garantizar la reproducibilidad técnica del proyecto, se ha establecido un entorno controlado mediante Python y la gestión de dependencias con el archivo requirements.txt. Este archivo contiene todas las librerías necesarias para ejecutar los notebooks del proyecto sin errores, permitiendo que cualquier integrante del equipo o evaluador pueda replicar los resultados en su propio entorno.

Todos los notebooks y scripts están organizados dentro de un repositorio en GitHub, lo que asegura el **control de versiones**, registro histórico de cambios y disponibilidad centralizada de los archivos de trabajo y datasets asociados. La estructura de carpetas se ha diseñado para separar datos originales, datos procesados, documentación y notebooks, facilitando la navegación y la ejecución de los análisis.

Se ha verificado que la carga de datos y la inicialización de notebooks se puede realizar sin errores en un entorno limpio, cumpliendo con los criterios de ejecución y activación. Esta estrategia permite que el proyecto sea íntegramente reproducible en cualquier equipo, asegurando que todos los pasos desde la adquisición de los datos hasta la preparación inicial estén documentados y sean ejecutables sin modificaciones adicionales.

Procedimiento para crear el entorno reproducible:

1. Clonar el repositorio

git clone https://github.com/ffarina11/proyecto-grupo7-mcdi500

2. Crear entorno virtual

python -m venv .venv

3. Activar entorno virtual

Windows:

.venv\Scripts\activate

macOS/Linux:

source .venv/bin/activate

4. Instalar dependencias/ librerías

pip install -r requirements.txt

5. Abrir Jupyter Lab

jupyter lab

```
(.venv) (base) C:\Users\juan.diaz\proyecto-grupo7-mcdi500>pip list | findstr /I "pandas numpy matplotlib jupyterlab ipykernel scikit
seaborn"
ipykernel                7.2.0
jupyterlab               4.5.8
jupyterlab_pygments      0.3.0
jupyterlab_server        2.28.0
matplotlib               3.10.9
matplotlib-inline        0.2.2
numpy                    2.4.6
pandas                   3.0.3
scikit-learn             1.9.0
seaborn                  0.13.2
(.venv) (base) C:\Users\juan.diaz\proyecto-grupo7-mcdi500>
```


```
Downloading soupsieve-2.8.4-py3-none-any.whl.metadata (4.6 kB)
Collecting arrow>=0.15.0 (from isoduration->jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.11.0->jupyter-server<3,>=2.4.0->jupy
terlab>=4.2.0->-r requirements.txt (line 4))
  Downloading arrow-1.4.0-py3-none-any.whl.metadata (7.7 kB)
Downloading pandas-3.0.3-cp313-cp313-win_amd64.whl (9.8 MB)
   9.8/9.8 MB 69.2 MB/s 0:00:00
Downloading numpy-2.4.6-cp313-cp313-win_amd64.whl (12.3 MB)
   12.3/12.3 MB 53.9 MB/s 0:00:00
Downloading matplotlib-3.10.9-cp313-cp313-win_amd64.whl (8.2 MB)
   8.2/8.2 MB 39.1 MB/s 0:00:00
Downloading jupyterlab-4.5.8-py3-none-any.whl (12.4 MB)
   12.4/12.4 MB 23.0 MB/s 0:00:00
Downloading httpx-0.28.1-py3-none-any.whl (73 kB)
Downloading httpcore-1.0.9-py3-none-any.whl (78 kB)
Downloading jupyter_server-2.19.0-py3-none-any.whl (392 kB)
Downloading jupyterlab_server-2.28.0-py3-none-any.whl (59 kB)
Downloading ipykernel-7.2.0-py3-none-any.whl (118 kB)
Downloading scikit_learn-1.9.0-cp313-cp313-win_amd64.whl (8.2 MB)
   8.2/8.2 MB 52.9 MB/s 0:00:00
Downloading seaborn-0.13.2-py3-none-any.whl (294 kB)
Downloading anyio-4.13.0-py3-none-any.whl (114 kB)
Downloading argon2_cffi-25.1.0-py3-none-any.whl (14 kB)
Downloading async_lru-2.3.0-py3-none-any.whl (8.4 kB)
Downloading babel-2.18.0-py3-none-any.whl (10.2 MB)
   10.2/10.2 MB 22.6 MB/s 0:00:00
Downloading comm-0.2.3-py3-none-any.whl (7.3 kB)
Downloading contourpy-1.3.3-cp313-cp313-win_amd64.whl (226 kB)
Downloading cycycler-0.12.1-py3-none-any.whl (8.3 kB)
Downloading debugpy-1.8.21-cp313-cp313-win_amd64.whl (5.4 MB)
   5.4/5.4 MB 71.6 MB/s 0:00:00
Downloading fonttools-4.63.0-cp313-cp313-win_amd64.whl (2.3 MB)
   2.3/2.3 MB 52.6 MB/s 0:00:00
Downloading h11-0.16.0-py3-none-any.whl (37 kB)
Downloading idna-3.18-py3-none-any.whl (65 kB)
Downloading ipython-9.14.1-py3-none-any.whl (627 kB)
   627.8/627.8 kB 54.4 MB/s 0:00:00
Downloading prompt_toolkit-3.0.52-py3-none-any.whl (391 kB)
Using cached colorama-0.4.6-py2.py3-none-any.whl (25 kB)
```

V. Control de versiones

Desde el inicio del proyecto se ha implementado un control de versiones utilizando **Git** como sistema de gestión local y **GitHub** como repositorio remoto centralizado. Cada cambio significativo en los notebooks, scripts y documentación se registra mediante **commits descriptivos**, lo que permite mantener un historial claro y verificable de todas las modificaciones realizadas.

La estrategia de commits se ha planificado de manera que cada integrante del equipo pueda documentar sus contribuciones de forma independiente y trazable, favoreciendo la colaboración y la coherencia entre las distintas versiones del proyecto. Esto incluye la creación de ramas para funcionalidades específicas o correcciones cuando corresponde, asegurando que el historial principal (**main**) se mantenga estable y que cada modificación pueda revisarse individualmente.

El repositorio en GitHub contiene la **estructura completa del proyecto**, incluyendo notebooks, scripts, archivos de datos y documentación, permitiendo que cualquier integrante del equipo o evaluador pueda reproducir los cambios y verificar la evolución del proyecto en cualquier momento. Esta práctica garantiza un flujo de trabajo organizado, transparente y alineado con las buenas prácticas de desarrollo reproducible en proyectos de ciencia de datos.



Commit Message	User	Time	Hash
Merge branch 'main' of https://github.com/ffarina11/proyecto-grupo7-mcdi500	ffarina11	committed 24 minutes ago	149e9b5
Actualiza librerías	ffarina11	committed 26 minutes ago	f147edd
Agregar archivo de funciones	yenneseputveda	committed 1 hour ago	9579e1d
actualiza librerías	Juan de Dios Diaz Rios	committed 1 hour ago	592736b
Commits on Jun 7, 2026			
Merge branch 'main' of https://github.com/ffarina11/proyecto-grupo7-mcdi500	ConstanzaM0	committed 18 hours ago	93627a8
agrega módulo librerías para gestión de datasets	ConstanzaM0	committed 18 hours ago	d9354f2
Agrega Definición de Notebook	yenneseputveda	committed 19 hours ago	c888ed8
agrega dataset original	Juan de Dios Diaz Rios	committed 19 hours ago	fc5477d
actualizar README con instrucciones y estructura del proyecto	ConstanzaM0	committed 19 hours ago	dd25239
Inicializa estructura del proyecto	ffarina11	committed 20 hours ago	09634cc

Para asegurar la trazabilidad de las contribuciones, cada integrante del equipo registra sus avances mediante commits descriptivos. Esta práctica permite identificar rápidamente el propósito de cada modificación y facilita el seguimiento de la evolución del proyecto a través del historial disponible en GitHub.

VI. Notebook F1_Definicion.ipynb

El notebook **F1_Definicion.ipynb** constituye la base del proyecto, integrando de manera coherente la problemática, los objetivos y la estructura inicial del análisis de datos. Cada celda narrativa documenta el propósito de las acciones realizadas, proporcionando contexto antes de ejecutar el código, lo que asegura que cualquier lector pueda entender los pasos del proceso sin depender de información externa.

La sección de código inicial incluye la carga de los datasets (student-mat.csv y student-por.csv) y la verificación de su estructura mediante Pandas (head(), info(), describe()), garantizando que los datos estén listos para análisis posteriores. Se han documentado también las decisiones de preparación de los datos, como la creación de columnas relevantes y la separación de datasets en carpetas **raw** y **processed**, asegurando coherencia con la estructura del repositorio en GitHub.

El notebook ha sido ejecutado sin errores, evidenciando que todo el código base funciona correctamente y que la información presentada es reproducible por cualquier integrante del equipo o evaluador. Cada sección del notebook mantiene una **integración clara entre narrativa y código**, cumpliendo con los criterios de trazabilidad, coherencia y documentación requerida por la fase inicial del proyecto.

Este notebook se encuentra centralizado en el repositorio de GitHub, vinculado con el resto de la documentación y datos del proyecto, asegurando que el flujo entre la información presentada en el informe y la evidencia técnica sea consistente y verificable.

URL del proyecto GitHub: (<https://github.com/ffarina11/proyecto-grupo7-mcdi500>).

localhost:8888/lab/tree/notebooks/F1_Definicion.ipynb

File Edit View Run Kernel Git Tabs Settings Help

data 23 hr. ago
docs yesterday
notebooks 1 sec. ago
Semana1 23 hr. ago
src 7 min. ago
README.md 22 hr. ago
requirements.txt 3 hr. ago

F1_Definicion.ipynb x MINGW64C:\Users\ffm3\Or X librerias.py x functions.py x + Notebook Python 3 (ipykernel)

MCDI500 — Programación para la ciencia de datos

Proyecto Transversal — Fase 1: Definición del Problema

Título del proyecto: Factores socioeconómicos y de preparación previa asociados al rendimiento académico

Campo	Detalle
Curso	MCDI500 — Programación para la ciencia de datos
Docente	Omar Salinas Silva
Grupo	Grupo 7
Integrantes	Juan de Dios Díaz Ríos · Francisco Farfán Molina · Constanza Moreno Giacometto · Yenne Sepúlveda Jerez
Fecha	Junio 2026
Dataset	Student Performance Dataset (Cortez & Silva, 2008) — UCI Machine Learning Repository

Índice

1. Contextualización del proyecto
2. Definición de la problemática
3. Objetivos del proyecto
4. Alcance y supuestos
5. Descripción del dataset
6. Configuración del entorno reproducible
7. Carga inicial del dataset
8. Exploración preliminar de variables
9. Vinculación con el mapa conceptual
10. Referencias

1. Contextualización del proyecto

El rendimiento académico de los estudiantes es un fenómeno multidimensional influenciado por factores individuales, familiares, socioeconómicos e institucionales. En contextos de

Simple 1 1 main Python 3 (ipykernel) | idle Mode: Command

VII. Documentación del proceso

Cada paso de la preparación de datos, desde la descarga de los archivos originales hasta la organización en carpetas **raw** y **processed**, se documentó mediante celdas Markdown en los notebooks y en el README del repositorio.

Durante esta fase 1 del proyecto, se mantuvo un registro detallado de todas las decisiones técnicas y operativas tomadas, asegurando un flujo de trabajo claro y verificable. Se decidió mantener las dos fuentes de datos en archivos independientes y cargarlas por separado en Jupyter Lab, en lugar de unificarlas desde el inicio. Esta decisión responde a criterios metodológicos y de reproducibilidad, ya que permite conservar la estructura original de cada conjunto de datos, facilitar la trazabilidad de la información y evitar modificaciones prematuras que puedan introducir errores o sesgos.

Asimismo, la integración de ambas fuentes no constituye un requisito en esta etapa del proyecto, cuyo alcance se limita a la adquisición, exploración y preparación inicial de los datos. Mantener los archivos separados permite realizar un análisis individual de las características, tipos de variables y calidad de cada fuente antes de evaluar la conveniencia de una eventual unificación en etapas posteriores.

De esta manera, se resguarda la integridad de los datos originales y se favorece un proceso de trabajo más transparente, reproducible y consistente con las buenas prácticas de Ciencia de Datos.

Se registraron también las decisiones sobre la estructura del notebook, la nomenclatura de archivos y carpetas, así como la inclusión de **.gitignore** y **requirements.txt** para garantizar la reproducibilidad. Cada cambio realizado en los notebooks o en los datos se justificó indicando el motivo y el impacto esperado, de manera que cualquier miembro del equipo o evaluador pueda comprender el flujo de trabajo completo.

Esta documentación mantiene coherencia total con el informe de la Formativa 1 y con la organización del repositorio en GitHub, permitiendo trazar desde la definición del problema y objetivos, hasta la preparación de los datos y la configuración inicial del proyecto. La estrategia asegura que todas las decisiones técnicas queden registradas y accesibles, facilitando futuras fases de análisis y modelado, así como la replicación del trabajo por otros integrantes.

VIII. Repositorio GitHub correspondiente a la Fase 1

El repositorio del proyecto en GitHub refleja de manera íntegra la estructura de trabajo definida para la fase inicial del proyecto. La carpeta **F1** contiene todos los notebooks, datos y documentación correspondientes, organizados de manera coherente con el mapa conceptual del proyecto y con la estructura de carpetas descrita en el informe.

El archivo **README.md** proporciona instrucciones claras de uso, describe la estructura de los directorios y detalla cómo ejecutar los notebooks, garantizando que cualquier integrante del equipo o evaluador pueda reproducir los pasos sin omisiones. Cada commit realizado en el repositorio es **informativo y descriptivo**, registrando de manera individual la contribución de cada integrante y documentando decisiones técnicas clave.

Esta integración asegura que el repositorio sea totalmente reproducible, que la trazabilidad entre notebooks, datos y documentación sea clara, y que no existan omisiones en la evidencia del proyecto. La sincronización entre GitHub y los notebooks permite mantener coherencia con el informe, demostrando que todo el flujo de trabajo es verificable y consistente desde la definición del problema hasta la preparación de los datos.

URL del proyecto GitHub: (<https://github.com/ffarina11/proyecto-grupo7-mcdi500>)

IX. Vinculación del mapa conceptual con el avance del proyecto

El mapa conceptual funciona como una guía técnica del proyecto, ya que organiza las etapas del flujo reproducible y relaciona cada proceso con las herramientas del ecosistema científico. En la Fase 1 se materializan principalmente la definición del problema, la planificación de la carga del dataset, la configuración del entorno, la estructura del repositorio y la documentación inicial. Las etapas de exploración, limpieza, análisis, modelado y evaluación quedan proyectadas para fases posteriores, manteniendo coherencia con la secuencia técnica representada.

Elemento del Mapa Conceptual	¿Dónde se materializó?
Definición del problema	Se redacta la problemática, pregunta guía, objetivo general y objetivos específicos. Archivo F1_Definicion.ipynb en carpeta notebooks/ de proyecto.
Carga del dataset	Se crean carpetas data/raw y se planifica la carga de student-mat.csv y student-por.csv.
Exploración de datos (EDA)	Queda proyectada para Fase 2
Limpieza y preparación	Queda proyectada para Fase 2
Análisis y modelado	Queda proyectado para fases posteriores con regresión lineal y árboles de decisión.
Evaluación y comunicación	Queda proyectada para fases posteriores con visualizaciones y conclusiones.
Documentación reproducible	Se materializa mediante README, notebook, requirements.txt y registro de decisiones.
Herramientas transversales	Git, GitHub, Python y Jupyter Lab se usan para organizar, versionar, analizar y documentar.


El avance desarrollado en la Fase 1 mantiene una correspondencia directa con la planificación establecida en el mapa conceptual del proyecto. En particular, se completaron las actividades relacionadas con la obtención y almacenamiento de los datasets originales, la organización de carpetas para datos y notebooks, la creación del entorno reproducible mediante Python y la gestión de dependencias, así como la implementación del notebook inicial **F1_Definicion.ipynb**. Estos elementos constituyen la base técnica necesaria para las siguientes etapas del proyecto.

Las fases posteriores estarán orientadas al análisis exploratorio de datos, la generación de visualizaciones mediante Matplotlib, la preparación avanzada de variables y la implementación

de modelos de aprendizaje automático utilizando Scikit-Learn. Estas actividades permitirán responder la pregunta de investigación planteada y contrastar los objetivos definidos en la etapa inicial.

La correspondencia entre lo planificado y lo ejecutado permite verificar que el proyecto avanza de manera consistente respecto de la planificación original, manteniendo trazabilidad entre los objetivos, los productos desarrollados y las actividades proyectadas para las siguientes fases.

Mapa conceptual base utilizado para vincular planificación y avance técnico:



X. Bibliografía (APA 7)

Cortez, P., & Silva, A. (2008). *Using data mining to predict secondary school student performance*. University of Minho. <https://archive.ics.uci.edu/dataset/320/student+performance>

Dua, D., & Graff, C. (2019). *UCI Machine Learning Repository*. University of California, Irvine, School of Information and Computer Sciences. <https://archive.ics.uci.edu>

García, S., Luengo, J., & Herrera, F. (2015). *Data preprocessing in data mining*. Springer.

NumPy Developers. (2024). *NumPy documentation*. <https://numpy.org/doc/stable/>

Salinas, O. (2026a). *Actividades de la Semana 1: Fundamentos avanzados de Python y buenas prácticas* [Presentación de clase]. MCDI500 — Programación para la Ciencia de Datos, Universidad Andrés Bello.

Salinas, O. (2026b). *Tareas prácticas de las Fases 1 y 2: Fuentes de datos, variables categóricas, limpieza, datos perdidos, escalamiento y encoding* [Presentación de clase]. MCDI500 — Programación para la Ciencia de Datos, Universidad Andrés Bello.

The pandas development team. (2024). *pandas documentation*. <https://pandas.pydata.org/docs/>

Universidad Andrés Bello. (2026a). *Guía de Git y GitHub: Entorno de desarrollo con Python y JupyterLab. Versión para Windows 10 y 11* [Material de apoyo]. Universidad Andrés Bello, Santiago.

Universidad Andrés Bello. (2026b). *Crear entornos reproducibles en GitHub* [Interactivo]. Universidad Andrés Bello, Santiago.